

USULAN PENELITIAN DISERTASI
DATA ALIGNMENT BERBASIS PROBABILISTIC
ENTITY RESOLUTION DAN DETEKSI ANOMALI
KEPATUHAN YANG TERINTEGRASI DENGAN
RETRIEVAL AUGMENTED GENERATION

(DATA ALIGNMENT BASED ON PROBABILISTIC
ENTITY RESOLUTION AND COMPLIANCE ANOMALY
DETECTION INTEGRATED WITH RETRIEVAL
AUGMENTED GENERATION)

disusun dan diajukan oleh
Benny Leonard Enrico Panggabean
D063251008



PROGRAM STUDI DOKTOR TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS HASANUDDIN
MAKASSAR
2025

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pendidikan tinggi di Indonesia memegang peran sentral dalam pembangunan sumber daya manusia unggul, pengembangan ilmu pengetahuan dan teknologi, serta kontribusi terhadap kesejahteraan masyarakat melalui tridharma perguruan tinggi. Untuk menjamin mutu penyelenggaraan tridharma tersebut, pemerintah melalui Kementerian Pendidikan, Kebudayaan, Riset, dan Teknologi menetapkan Permendikbudristek Nomor 39 Tahun 2025 tentang Penjaminan Mutu Pendidikan Tinggi. Peraturan ini memperbarui ketentuan sebelumnya pada Permendikbudristek Nomor 53 Tahun 2023, dengan penekanan pada penguatan integrasi sistem mutu dengan Pangkalan Data Pendidikan Tinggi (PDDikti) dan peningkatan relevansi standar mutu pendidikan tinggi terhadap perkembangan global. Permendikbudristek Nomor 39 Tahun 2025 menegaskan bahwa penjaminan mutu pendidikan tinggi dilaksanakan secara sistemik, terencana, berkelanjutan, dan menyeluruh, meliputi standar pendidikan, penelitian, dan pengabdian kepada masyarakat yang dirumuskan dalam Standar Nasional Pendidikan Tinggi (SN-Dikti). Perguruan tinggi wajib melaksanakan Sistem Penjaminan Mutu Internal (SPMI) dan mengikuti Sistem Penjaminan Mutu Eksternal (SPME) melalui mekanisme akreditasi. PDDikti menjadi rujukan utama dalam memantau kepatuhan terhadap SN-Dikti, sekaligus menjadi instrumen strategis untuk penilaian kinerja, akreditasi, dan pengambilan kebijakan. Kualitas data yang dilaporkan ke PDDikti sangat menentukan akuntabilitas dan kredibilitas perguruan tinggi. Data yang tidak sinkron, tidak akurat, atau tidak sesuai regulasi dapat berdampak langsung pada penurunan status akreditasi, berkurangnya kepercayaan publik, hingga menimbulkan kerugian bagi mahasiswa. Faktanya, dalam praktik pelaporan akademik melalui Sistem Informasi Akademik (SIKAD) internal dan FEEDER PDDikti, sering ditemukan berbagai masalah:

1. Ketidaksinkronan data, misalnya perbedaan penulisan nama mahasiswa/dosen atau perbedaan jumlah SKS.
2. Perbedaan struktur data antara SIKAD dan FEEDER
3. Anomali kepatuhan, seperti dosen tercatat mengajar lebih dari 16 SKS per semester, mahasiswa aktif melebihi daya tampung resmi, atau mahasiswa dengan masa studi

melebihi ketentuan tanpa status jelas.

Kondisi ini menjadi tantangan besar, terutama di daerah dengan jumlah perguruan tinggi yang signifikan. Berdasarkan data Pangkalan Data Perguruan Tinggi pada tahun 2025, terdapat 367 perguruan tinggi (negeri dan swasta) di Provinsi Sulawesi Selatan. Angka tersebut mencerminkan keragaman kapasitas dan sumber daya institusi, yang seluruhnya wajib melaporkan data akademik secara akurat dan konsisten ke PDDikti. Kompleksitas ini mempertegas pentingnya solusi teknologi untuk memastikan keselarasan data dan kepatuhan regulasi. Perkembangan teknologi kecerdasan buatan (AI) memberikan peluang untuk mengatasi permasalahan ini. Probabilistic Entity Resolution (ER) memungkinkan penyelarasan data antar sistem dengan memperhitungkan perbedaan format, struktur, maupun variasi penulisan. Dengan pendekatan probabilistik, sistem dapat menghitung tingkat keyakinan (confidence score) apakah dua entitas dari SIAKAD dan FEEDER merepresentasikan individu atau unit yang sama. Setelah data selaras, deteksi anomali kepatuhan menjadi tahap krusial berikutnya. Pendekatan hybrid yang menggabungkan aturan regulasi (rule-based) dan machine learning (misalnya Isolation Forest, Local Outlier Factor, atau Autoencoder) dapat mendeteksi ketidakwajaran dalam data. Contohnya, sistem bisa menandai dosen dengan beban SKS berlebih, mahasiswa yang ganda, atau prodi yang melaporkan daya tampung tidak konsisten. Hasil dari entity resolution dan anomaly detection ini kemudian dapat diintegrasikan ke dalam Retrieval-Augmented Generation (RAG). Dengan mekanisme ini, pimpinan program studi dapat mengajukan pertanyaan, dan sistem akan memberikan jawaban berbukti yang menggabungkan regulasi resmi (Permendikbudristek No. 39 Tahun 2025) dengan data ter-align dari SIAKAD–FEEDER serta temuan anomali kepatuhan. Jawaban dilengkapi dengan sitasi dan confidence score, sehingga dapat dipertanggungjawabkan. Dengan demikian, penelitian mengenai “Data alignment berbasis probabilistic entity resolution dan deteksi anomali kepatuhan yang terintegrasi RAG” memiliki urgensi tinggi. Penelitian ini tidak hanya menjawab masalah teknis sinkronisasi dan validasi data akademik, tetapi juga mendukung implementasi regulasi terbaru, yaitu Permendikbudristek Nomor 39 Tahun 2025, sekaligus memperkuat sistem penjaminan mutu pendidikan tinggi di Indonesia. Melalui kontribusi akademis dan praktis, penelitian ini diharapkan dapat meningkatkan kualitas tata kelola data, mendukung akreditasi, dan memperkuat kepercayaan publik terhadap perguruan tinggi, khususnya di Provinsi Sulawesi Selatan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka rumusan masalah penelitian ini dapat dirumuskan sebagai berikut:

1. Menganalisis perbedaan struktur, format, dan kualitas data antara sistem SIAKAD internal perguruan tinggi dengan FEEDER PDDikti, serta dampaknya terhadap mutu pelaporan akademik dan kepatuhan regulasi pendidikan tinggi.
2. Mengevaluasi efektivitas metode *probabilistic entity resolution* dalam menyelaraskan data antar sistem (*data alignment*), khususnya untuk entitas mahasiswa, dosen, program studi, dan mata kuliah dengan mempertimbangkan konteks data akademik Indonesia.
3. Merancang model deteksi anomali kepatuhan (*compliance anomaly detection*) berbasis pendekatan hybrid (*rule-based* dan *machine learning*) untuk mengidentifikasi pelanggaran terhadap standar regulasi, seperti beban SKS dosen, daya tampung mahasiswa, dan masa studi.
4. Mengintegrasikan hasil *entity resolution* dan *anomaly detection* dengan pendekatan *Retrieval-Augmented Generation (RAG)* agar dapat menghasilkan jawaban tanya-jawab akademik yang akurat, terbukti, dan selaras dengan regulasi yang berlaku.
5. Mengukur dan membandingkan performa sistem yang diusulkan dengan baseline eksisting, menggunakan metrik evaluasi seperti *precision*, *recall*, *F1-score* (*entity resolution*), *AUC* dan *anomaly detection*, serta *citation precision* dan *faithfulness (RAG)*.
6. Mendesain kerangka evaluasi *end-to-end* yang menggabungkan aspek teknis (akurasi, performa), aspek regulatif (kepatuhan terhadap Permendikbudristek Nomor 39 Tahun 2025), serta aspek praktis (kebermanfaatan bagi pimpinan program studi dalam pengambilan keputusan).

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis karakteristik ketidaksinkronan data antara SIAKAD dan FEEDER PDDikti, termasuk variasi struktur, format, serta standar penulisan, guna memahami sumber masalah dalam pelaporan akademik.

2. Mengevaluasi penerapan metode probabilistic entity resolution untuk penyelarasan data akademik, dengan membandingkan kinerjanya terhadap pendekatan rule-based tradisional.
3. Merancang model deteksi anomali kepatuhan berbasis pendekatan hybrid (rule-based dan machine learning) yang mampu mengidentifikasi dan mengklasifikasikan ketidaksesuaian dengan regulasi pendidikan tinggi.
4. Mengintegrasikan hasil entity resolution dan anomaly detection ke dalam sistem Retrieval-Augmented Generation (RAG), sehingga sistem dapat memberikan jawaban berbukti yang akurat, konsisten, dan sesuai regulasi.
5. Mengukur dan membandingkan efektivitas sistem yang diusulkan dengan baseline eksisting menggunakan metrik kuantitatif (precision, recall, F1-score, AUC, citation precision, faithfulness) dan evaluasi kualitatif (user study dengan pimpinan program studi).
6. Mengembangkan kerangka evaluasi end-to-end untuk sistem audit kepatuhan akademik berbasis Kecerdasan Buatan yang selaras dengan regulasi terbaru, yakni Permendikbudristek Nomor 39 Tahun 2025, serta relevan untuk peningkatan mutu tata kelola pendidikan tinggi di Indonesia.

1.4 Batasan Masalah

Agar penelitian ini terarah dan fokus, maka ruang lingkup penelitian dibatasi pada hal-hal berikut:

1. Objek Data, Data bersumber dari Sistem Informasi Akademik (SIKAD) internal perguruan tinggi dan FEEDER PDDikti sebagai kanal pelaporan resmi.
2. Cakupan Regulasi, Regulasi yang dijadikan rujukan utama adalah Permendikbudristek Nomor 39 Tahun 2025 tentang Penjaminan Mutu Pendidikan Tinggi, serta aturan terkait standar beban dosen, masa studi, daya tampung, dan standar akreditasi. Peraturan sebelumnya seperti Permendikbudristek Nomor 53 Tahun 2023 diposisikan sebagai referensi historis.
3. Metode Teknis

- Entity Resolution difokuskan pada pendekatan probabilistik yang dapat dipadukan dengan pembelajaran mesin (machine learning) dan representasi berbasis embedding.
- Deteksi anomali kepatuhan difokuskan pada metode hybrid: aturan regulasi (rule-based) dan algoritma deteksi outlier (misalnya Isolation Forest, LOF, Autoencoder).
- RAG (Retrieval-Augmented Generation) difokuskan pada integrasi dengan data hasil alignment dan anomaly detection, bukan pada pengembangan arsitektur LLM baru.

4. Ruang Evaluasi

- Evaluasi sistem dilakukan melalui metrik kuantitatif (precision, recall, F1-score, AUC, faithfulness) dan studi pengguna (user study) pada level pimpinan program studi.
- Penelitian tidak mencakup implementasi skala nasional di semua perguruan tinggi, melainkan studi kasus yang dapat digeneralisasikan.

1.5 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat pada tiga level: teoritis, praktis, dan kebijakan.

1. Manfaat Teoritis

- Memberikan kontribusi pada pengembangan ilmu di bidang data integration, anomaly detection, dan retrieval-augmented generation.
- Menghasilkan kerangka metodologis baru untuk confidence-aware RAG yang menggabungkan probabilistic entity resolution dan anomaly detection.

2. Manfaat Praktis

- Menyediakan prototipe sistem audit kepatuhan akademik berbasis AI yang dapat digunakan oleh perguruan tinggi.
- Membantu pimpinan program studi dalam mengambil keputusan cepat, akurat, dan terbukti, terutama terkait kepatuhan regulasi dan pelaporan data.
- Menurunkan beban kerja manual staf akademik dalam sinkronisasi data SIAKAD-FEEDER.

3. Manfaat Kebijakan

- Mendukung implementasi Permendikbudristek Nomor 39 Tahun 2025 melalui penyediaan mekanisme audit kepatuhan berbasis data dan Kecerdasan Buatan.
- Menjadi masukan bagi pemerintah dan lembaga akreditasi dalam menyusun kebijakan penjaminan mutu berbasis data yang lebih adaptif dan transparan.
- Memberikan landasan bagi pengembangan standar evaluasi nasional dalam integritas data akademik dan pelaporan PDDikti.

BAB II

TINJAUAN PUSTAKA

2.1 Data Alignment dan Entity Resolution

Entity Resolution (ER) merupakan proses identifikasi dan penyelarasan entitas yang merujuk pada objek yang sama dari dua atau lebih sumber data berbeda. Model klasik yang menjadi dasar teori adalah pendekatan probabilistik yang dikembangkan oleh Fellegi dan Sunter [5], yang menggunakan likelihood untuk memutuskan apakah dua catatan merupakan *match* atau *non-match*. Seiring perkembangan teknologi, metode ER berkembang dari teknik rule-based menuju pembelajaran mesin [3]. Pendekatan modern berbasis deep learning seperti DeepMatcher [16] dan Ditto [13] menawarkan peningkatan akurasi dengan memanfaatkan representasi teks berbasis *pre-trained language models*. Saat ini, kerangka kerja probabilistik berskala besar seperti Splink juga banyak digunakan dalam integrasi data publik [17].

2.2 Deteksi Anomali (Outlier Detection dan Compliance)

Deteksi anomali adalah metode untuk menemukan data yang menyimpang dari pola umum. Metode berbasis densitas seperti Local Outlier Factor (LOF) [2], pohon acak seperti Isolation Forest [14], serta metode streaming seperti Random Cut Forest (RRCF) [6] banyak digunakan di berbagai domain. Untuk data pendidikan tinggi, deteksi anomali dapat digunakan untuk menemukan kasus pelanggaran regulasi, misalnya dosen dengan beban mengajar melebihi 16 SKS per semester. Toolkit PyOD[21] menjadi salah satu pustaka populer karena menyediakan berbagai algoritma deteksi outlier yang dapat digunakan untuk eksperimen cepat.

2.3 Retrieval-Augmented Generation (RAG)

RAG adalah paradigma yang menggabungkan pencarian informasi dengan model generatif untuk menghasilkan jawaban berbukti. Konsep ini diperkenalkan oleh Lewis dkk. [12], yang menunjukkan bahwa kombinasi retriever dan generator mampu menjawab pertanyaan berbasis pengetahuan dengan lebih baik dibandingkan model generatif murni. Perkembangan terbaru termasuk Self-RAG [19], di mana model dapat memutuskan kapan

melakukan retrieval dan melakukan self-critique, serta GraphRAG [18], yang memperkenalkan retrieval berbasis graf untuk menangani pertanyaan global. Mekanisme verifikasi sitasi juga terus dikembangkan untuk mengurangi risiko halusinasi [20].

2.4 Evaluasi Faithfulness dalam RAG

Salah satu tantangan besar dalam RAG adalah memastikan jawaban sesuai dengan sumber yang diambil. Fabbri dkk. mengusulkan QAFactEval [4], sebuah metrik untuk mengukur konsistensi jawaban dengan fakta dari korpus. Min dkk. mengembangkan FactScore [15], yang menguraikan jawaban menjadi fakta atomik untuk mengevaluasi tingkat dukungan sumber secara lebih granular.

2.5 Regulasi Pendidikan Tinggi di Indonesia

Dalam konteks pendidikan tinggi Indonesia, penjaminan mutu diatur melalui berbagai regulasi resmi. Standar Nasional Pendidikan Tinggi (SN-Dikti) ditetapkan dalam Permenristekdikti Nomor 51 Tahun 2018 [10], sedangkan sistem penjaminan mutu dijabarkan dalam Permenristekdikti Nomor 52 Tahun 2018 [11]. Lebih lanjut, sistem akreditasi program studi dan perguruan tinggi diatur dalam Permendikbudristek Nomor 50 Tahun 2024 [8]. Aturan terbaru terkait penjaminan mutu pendidikan tinggi adalah Permendikbudristek Nomor 39 Tahun 2025 [9], yang memperbarui Permendikbudristek Nomor 53 Tahun 2023 [7]. Regulasi ini menegaskan integrasi sistem penjaminan mutu dengan PDDikti sebagai basis evaluasi nasional.

2.6 Tabel State of the Art

Tabel 2.1 menyajikan perbandingan *state of the art* (SoTA) pada *Entity Resolution*, deteksi anomali kepatuhan, serta Retrieval-Augmented Generation (RAG) dan evaluasi faithfulness.

Table 2.1: State of the Art pada ER, Anomaly Detection, dan RAG

Area	Metode/Alat	Kelebihan	Kekurangan	Celah Penelitian
Entity Resolution	Fellegi–Sunter (1969) [5]	Interpretabel, probabilistik, butuh label minim	Kurang akurat untuk teks/noisy, sensitif <i>tuning</i>	Adaptasi domain pendidikan tinggi Indonesia (NIM/NIDN, ejaan)
	DeepMatcher [16]	Akurasi lebih tinggi pada teks panjang/kompleks	Perlu data label dan komputasi pelatihan	Evaluasi pada data akademik Indonesia (low-resource)
	Ditto [13]	SoTA PLM; dukung augmentasi dan penonjolan atribut	Resource intensif; bias bahasa jika korpus Indo terbatas	Adaptasi/penyulingan (distillation) PLM bahasa Indonesia untuk ER
	LLM-ER (zero/low-shot) [17]	Minim label; fleksibel dan tangguh OOD	Biaya inferensi; variansi hasil; perlu <i>guardrails</i>	Desain hibrida LLM + probabilistic yang stabil dan hemat biaya
Deteksi Anomali	Isolation Forest [14]	Cepat, robust untuk data tabular besar	Sensitif parameter; interpretasi terbatas	Hibrida rule + IF untuk kepatuhan (SKS, masa studi, daya tampung)
	LOF [2]	Deteksi outlier berbasis densitas lokal (cluster-aware)	$O(n^2)$; kurang skalabel untuk data sangat besar	LOF incremental/approx untuk data semesteran

Bersambung ke halaman berikutnya

Lanjutan Tabel 2.1

Area	Metode/Alat	Kelebihan	Kekurangan	Celah Penelitian
	RRCF [6]	Cocok untuk <i>streaming</i> ; dipakai di pipeline produksi	Implementasi relatif kompleks	Uji RRCF untuk snapshot/stream FEEDER akademik
	Autoencoder [1]	Menangkap pola non-linear multi-variat	Latih mahal; sulit dijelaskan (black-box)	<i>Explainable</i> AE (SHAP/rules) untuk audit kepatuhan
RAG & Faithfulness	RAG (Lewis dkk., 2020) [12]	Jawaban berbukti, up-to-date; hemat dibanding <i>fine-tune</i>	Kualitas sangat tergantung retrieval	Integrasi dengan data ter-align (ER) dan fakta kepatuhan
	GraphRAG (Microsoft, 2024) [18]	Baik untuk pertanyaan global/tematik lintas dokumen	Overhead membangun/merawat graf	GraphRAG khusus regulasi PT Indonesia + bukti multi-sumber
	Self-RAG (2023) [19]	<i>Retrieve-on-demand</i> + <i>self-critique</i> kurangi halusinasi	Tambah latensi dan kompleksitas orkestrasi	<i>Controller</i> yang memasukkan skor ER + anomaly
	QAFactEval [4], FactScore [15]	Metrik evaluasi factual/faithfulness	Perlu korpus referensi lengkap dan penandaan bukti	Adaptasi metrik untuk regulasi Indonesia (pasal/ayat/masa berlaku)

Berdasarkan Tabel 2.1, metode klasik seperti Fellegi–Sunter [5] tetap relevan sebagai baseline yang interpretabel, namun metode berbasis PLM (Ditto) [13] dan pendekatan LLM-ER [17] menawarkan akurasi/fleksibilitas lebih tinggi dengan biaya komputasi yang perlu dikelola. Pada deteksi anomali, IF [14], LOF [2], dan RRCF [6] memberi spektrum teknik dari tabular statis hingga *streaming*, sementara AE [1] cocok untuk pola non-linear namun menantang dalam penjelasan. Pada RAG, konsep dasar [12] telah berkembang menjadi GraphRAG [18] dan Self-RAG [19], tetapi kebutuhan evaluasi faithfulness tetap krusial [4], [15].

BAB III

KERANGKA KONSEPTUAL DAN HIPOTESIS PENELITIAN

3.1 Kerangka Konseptual

Penelitian ini didasarkan pada kebutuhan untuk menjamin mutu data akademik di perguruan tinggi sebagaimana diamanatkan dalam Permendikbudristek Nomor 39 Tahun 2025. Mutu data yang dilaporkan melalui SIAKAD ke FEEDER PDDikti harus akurat, konsisten, dan sesuai regulasi, sehingga dapat mendukung akreditasi, pemantauan Indikator Kinerja Utama (IKU), serta akuntabilitas publik. Kerangka konseptual penelitian ini dibangun melalui tiga komponen utama:

1. Data Alignment (Probabilistic Entity Resolution)

- Data dari SIAKAD dan FEEDER di-extract melalui proses ETL (Extract, Transform, Load).
- Dengan probabilistic entity resolution, entitas seperti mahasiswa, dosen, program studi, dan mata kuliah diselaraskan meskipun terdapat perbedaan struktur, format, atau penulisan.
- Hasil penyelarasan disimpan pada tabel `entity_link` yang berisi pasangan entitas dan confidence score.

2. Compliance Anomaly Detection

- Data yang sudah ter-align digunakan untuk mendeteksi anomali kepatuhan.
- Metode hybrid:
 - Rule-based → mengimplementasikan aturan eksplisit (misalnya beban SKS dosen ≤ 16 , masa studi ≤ 7 tahun).
 - Machine learning outlier detection (Isolation Forest, LOF, Autoencoder) → mendeteksi pola anomali yang tidak tertangkap aturan eksplisit.
- Hasil deteksi disimpan dalam tabel `anomaly_event`.

3. Retrieval-Augmented Generation (RAG)

- RAG menggabungkan dokumen regulasi (Permen, UU, SOP) dengan data hasil alignment + anomaly detection.

- Pertanyaan pengguna (Ketua Prodi) diproses oleh retriever (BM25 + dense) dan generator (LLM).
- Jawaban dilengkapi dengan citation verifier, confidence score, serta hasil anomaly detection → menghasilkan jawaban terbukti.

Secara konseptual, alur penelitian adalah:

Data SIAKAD dan FEEDER → Entity Resolution → Anomaly Detection → RAG (QA terbukti regulasi + data).

3.2 Diagram Kerangka Konseptual




Figure 3.1: Diagram Kerangka Konseptual

BAB IV

METODOLOGI PENELITIAN

4.1 Desain Penelitian

Penelitian ini dirancang dengan pendekatan *experimental research* berbasis rekayasa perangkat lunak dan analitik data. Fokus utamanya adalah membangun prototipe sistem audit kepatuhan akademik yang mengintegrasikan:

1. **Data Alignment (Probabilistic Entity Resolution)** antara SIAKAD internal dan FEEDER PDDikti.
2. **Compliance Anomaly Detection** berbasis metode hibrida (aturan regulasi + algoritma deteksi outlier).
3. **Retrieval-Augmented Generation (RAG)** untuk menjawab pertanyaan pimpinan program studi dengan bukti regulasi dan data hasil alignment.

Desain penelitian ini bersifat *design science research*, di mana kontribusi utama berupa model konseptual, algoritme, serta prototipe sistem yang divalidasi melalui uji coba dataset riil dan evaluasi kuantitatif maupun kualitatif.

4.2 Dataset Penelitian

Dataset yang digunakan terdiri atas tiga kategori:

1. **Data Akademik SIAKAD** (read-only) dari universitas studi kasus: mencakup data mahasiswa, dosen, mata kuliah, kelas, dan registrasi.
2. **Data FEEDER PDDikti** (read-only) sebagai kanal pelaporan resmi: mencakup entitas sepadan (mahasiswa, dosen, prodi, mata kuliah).
3. **Dokumen Regulasi Pendidikan Tinggi**: Permenristekdikti No. 51 dan 52 Tahun 2018, Permendikbudristek No. 50 Tahun 2024, Permendikbudristek No. 53 Tahun 2023, dan regulasi terbaru Permendikbudristek No. 39 Tahun 2025.

Untuk menjaga privasi, data mahasiswa/dosen akan dianonimkan. Dataset diproses melalui pipeline ETL ke dalam `staging_siakad_*`, `staging_feeder_*`, serta `regulation_*` sebelum dilakukan eksperimen.

4.3 Tahapan Eksperimen

Eksperimen penelitian terdiri atas lima tahap utama:

1. Preprocessing dan ETL

- Ekstraksi data SIAKAD–FEEDER ke tabel staging.
- Ekstraksi teks regulasi PDF dengan OCR + segmentasi layout (pasal, ayat, tabel).

2. Probabilistic Entity Resolution (ER)

- Pemodelan pasangan kandidat entitas (blocking berdasarkan kunci: NIM, NIDN, nama).
- Penghitungan skor probabilitas kesamaan dengan model Fellegi–Sunter, embedding (BERT/IndoBERT), dan classifier ML (LogReg/GBM).
- Output: tabel `entity_link` berisi pasangan entitas dan *confidence score*.

3. Deteksi Anomali Kepatuhan

- Penerapan aturan regulasi eksplisit (misalnya SKS dosen ≤ 16 , masa studi ≤ 7 tahun).
- Penerapan algoritme deteksi anomali: Isolation Forest, LOF, dan Autoencoder.
- Output: tabel `anomaly_event` berisi jenis anomali, skor, dan bukti regulasi.

4. Retrieval-Augmented Generation (RAG)

- Indeks dokumen regulasi dengan BM25 + dense embedding (FAISS).
- Integrasi hasil `entity_link` dan `anomaly_event` ke retriever.
- LLM (misalnya LLaMA 3.1 atau GPT-4) menghasilkan jawaban dengan sitasi bukti.

5. Integrasi Sistem dan Antarmuka Chatbot

- Pembuatan layanan API `/ask`, `/retrieve`, `/cite`.
- Antarmuka chatbot berbasis web untuk ketua program studi.
- Logging audit dan observability (monitoring performa, metrik keandalan).

4.4 Rencana Evaluasi

Evaluasi penelitian dilakukan melalui tiga dimensi:

1. Evaluasi Entity Resolution

- Metrik: Precision, Recall, F1-Score.
- Baseline: rule-based matching sederhana.

2. Evaluasi Anomaly Detection

- Metrik: AUC, Precision@k, interpretabilitas hasil.
- Validasi: perbandingan dengan catatan manual staf akademik.

3. Evaluasi RAG

- Faithfulness: QAFactEval, FactScore.
- Citation Precision: persentase jawaban yang benar-benar disertai bukti regulasi valid.
- Studi pengguna: wawancara dan kuesioner dengan pimpinan program studi untuk menilai kegunaan, akurasi persepsi, dan tingkat kepercayaan.

4. Evaluasi End-to-End

- Kecepatan respon sistem (latensi end-to-end).
- Kepatuhan terhadap Permendikbudristek No. 39 Tahun 2025.
- Dampak praktis: potensi pengurangan beban manual staf akademik.

4.5 Ringkasan

Metodologi penelitian ini membentuk alur sistematis: ETL → Entity Resolution → Anomaly Detection → RAG → Evaluasi. Pendekatan ini memastikan kontribusi penelitian tidak hanya pada level algoritmik, tetapi juga pada implementasi nyata sistem audit kepatuhan berbasis AI untuk pendidikan tinggi di Indonesia.

Daftar Pustaka

- [1] C. C. Aggarwal, *Outlier Analysis*. Springer, 2017.
- [2] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, “Lof: Identifying density-based local outliers,” in *Proceedings of the 2000 ACM SIGMOD international conference on Management of data*, ACM, 2000, pp. 93–104.
- [3] P. Christen, *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*. Springer, 2012.
- [4] A. R. Fabbri, W. Kryściński, B. McCann, C. Xiong, R. Socher, and D. R. Radev, “Qafacteval: Improved qa-based factual consistency evaluation for summarization,” *arXiv preprint arXiv:2112.08542*, 2021.
- [5] I. P. Fellegi and A. B. Sunter, “A theory for record linkage,” *Journal of the American Statistical Association*, vol. 64, no. 328, pp. 1183–1210, 1969.
- [6] S. Guha, N. Mishra, G. Roy, and O. Schrijvers, “Robust random cut forest based anomaly detection on streams,” in *International Conference on Machine Learning (ICML)*, 2016, pp. 2712–2721.
- [7] Kementerian Pendidikan, Kebudayaan, Riset, dan Teknologi Republik Indonesia, *Permendikbudristek nomor 53 tahun 2023 tentang penjaminan mutu pendidikan tinggi*, 2023.
- [8] Kementerian Pendidikan, Kebudayaan, Riset, dan Teknologi Republik Indonesia, *Permendikbudristek nomor 50 tahun 2024 tentang akreditasi program studi dan perguruan tinggi*, 2024.
- [9] Kementerian Pendidikan, Kebudayaan, Riset, dan Teknologi Republik Indonesia, *Permendikbudristek nomor 39 tahun 2025 tentang penjaminan mutu pendidikan tinggi*, 2025.
- [10] Kementerian Riset, Teknologi, dan Pendidikan Tinggi Republik Indonesia, *Permenristekdikti nomor 51 tahun 2018 tentang standar nasional pendidikan tinggi*, 2018.
- [11] Kementerian Riset, Teknologi, dan Pendidikan Tinggi Republik Indonesia, *Permenristekdikti nomor 52 tahun 2018 tentang sistem penjaminan mutu pendidikan tinggi*, 2018.
- [12] P. Lewis et al., “Retrieval-augmented generation for knowledge-intensive nlp tasks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [13] Y. Li, J. Li, Y. Suhara, A. Doan, and W.-C. Tan, “Deep entity matching with pre-trained language models,” *Proceedings of the VLDB Endowment*, vol. 14, no. 1, pp. 50–60, 2020.
- [14] F. T. Liu, K. M. Ting, and Z.-H. Zhou, “Isolation forest,” in *2008 Eighth IEEE International Conference on Data Mining*, IEEE, 2008, pp. 413–422.

- [15] S. Min, M. Lewis, et al., “Factscore: Fine-grained atomic evaluation of factual precision in long-form generation,” in *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, 2023.
- [16] S. Mudgal et al., “Deep learning for entity matching: A design space exploration,” in *Proceedings of the 2018 International Conference on Management of Data (SIGMOD)*, ACM, 2018, pp. 19–34.
- [17] R. Peeters et al., *Splink: Probabilistic record linkage at scale*, <https://moj-analytical-services.github.io/splink/>, 2022.
- [18] M. Research, *Graphrag: Leveraging graph-based retrieval for global and community question answering*, Technical Report, 2024.
- [19] X. Sun, X. Tang, X. Chen, et al., “Self-rag: Self-reflective retrieval-augmented generation,” *arXiv preprint arXiv:2310.11511*, 2023.
- [20] S. Zhang, K. Guu, et al., “Improving rag with citation verification,” in *Proceedings of the Annual Meeting of the Association for Computational Linguistics (ACL)*, 2022.
- [21] Y. Zhao, Z. Nasrullah, and Z. Li, “Pyod: A python toolbox for scalable outlier detection,” *Journal of Machine Learning Research*, vol. 20, no. 96, pp. 1–7, 2019.